Advanced Data Science

Zuil Pirola

UNIVERSIDADE
LUSÓFONA

Baselines and splitting discipline

Como avaliar modelos sem enganar a nós mesmos:

- Regressão: **SalePrice**
- Classificação: **price tier(Vamos criar)**
- Train / validation / test
- Baselines antes de modelos “sérios”
- Métricas escolhidas por significado, não por hábito

Quando um resultado parece bom, mas não significa muito

- RMSE = 24 000
- Accuracy = 0.71

Isto é bom? Comparado com o quê?

Sem baseline, não há referência
Sem split correto, não há confiança
Sem métrica adequada, não há interpretação

Train, validation e test: três papéis diferentes

Train, validation e test não são a mesma coisa:

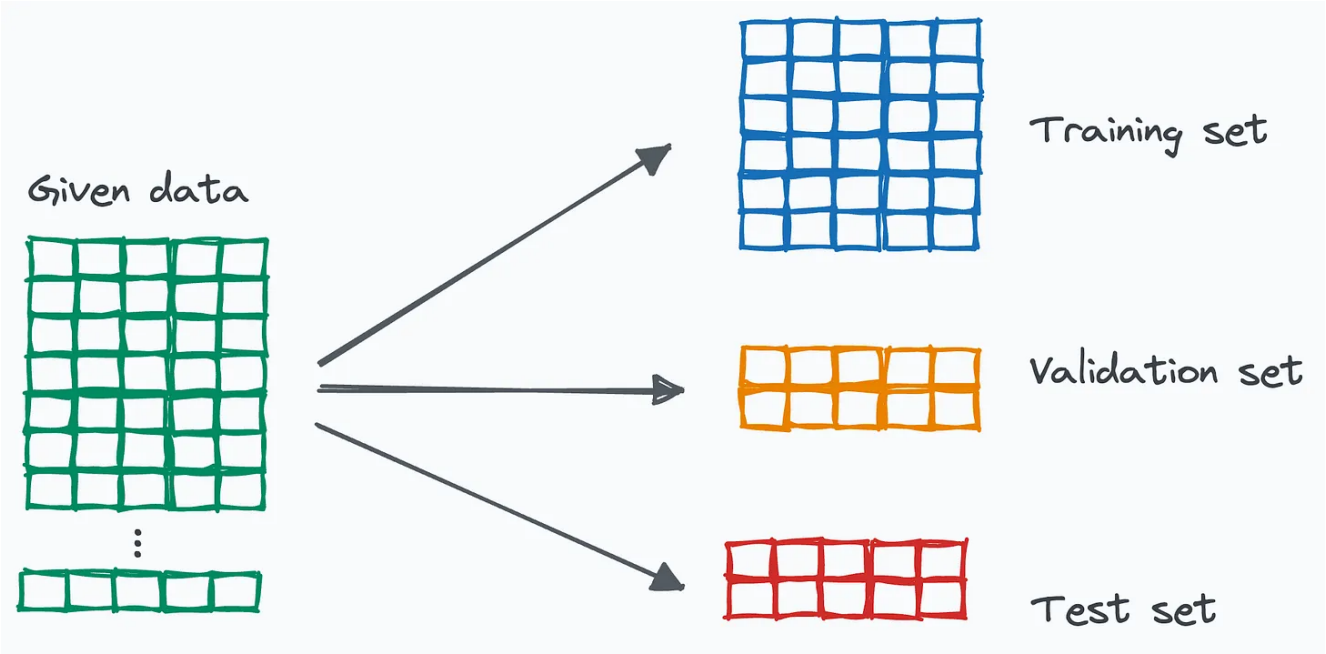

https://blog.dailydoseofds.com/p/how-to-actually-use-train-validation

Train, validation e test: três papéis diferentes

Train

- aprender padrões
- ajustar parâmetros
- estimar transformações
- construir o modelo

Validation

- comparar alternativas
- escolher entre pipelines
- ajustar hiperparâmetros
- decidir o que fica

Test

- avaliação final
- uso único no fim
- estimativa honesta de generalização

Train learns. Validation chooses. Test judges.

Primeiro dividir, depois aprender

Tudo o que aprende com os dados deve ser ajustado no treino

Errado (leakage)

- imputar antes do split
- normalizar antes do split
- selecionar variáveis antes do split
- agrupar níveis raros usando o dataset inteiro

Certo

- dividir primeiro
- ajustar preprocessing no treino
- aplicar as regras aprendidas à validação e ao teste

Baseline = a referência mínima para dizer que houve progresso

- Um baseline é um modelo simples e explícito
- Serve para dar contexto ao desempenho
- Não é “um modelo mau”; é uma referência honesta
- Sem baseline, um score isolado não tem significado claro

Better than what?

Exemplo

- Regressão: prever sempre o mesmo valor
- Classificação: prever sempre a classe mais frequente

Baselines para regressão: média e mediana

Duas referências simples antes de qualquer modelo com features

Baseline 1 — média do treino

Para todas as casas, prever:
$\hat{y}$ = mean(SalePrice_train)

Baseline 2 — mediana do treino

Para todas as casas, prever:
$\hat{y}$ = median(SalePrice_train)

Baselines para regressão: média e mediana

y_i (valor real)

$\hat{y}_i$ (valor previsto)

$$e_i = y_i - \hat{y}_i$$

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

Baselines para classificação: maioria e o perigo da accuracy

A referência mínima para a tarefa de classe de preço
Para todas as casas, prever:

$$\hat{y}_i = \text{mode}(price_tier_{train})$$

Isto significa:

- olha-se para a distribuição das classes no treino;
- identifica-se a classe mais frequente;
- essa classe é prevista para **todas** as observações da validação.

Baselines para classificação: maioria e o perigo da accuracy

Casa	classe real	previsão baseline
1	low	mid
2	mid	mid
3	high	mid
4	mid	mid

Acertos:

- 2 em 4

$$Accuracy = 2/4 = 0.50$$

$$Accuracy = \frac{\text{número de previsões corretas}}{\text{número total de observações}}$$

Quando a accuracy engana

Distribuição real das classes

low = 20
mid = 60
high = 20

$$Accuracy = \frac{60}{100} = 0.60$$

Balanced Accuracy

$$Balanced\ Accuracy = \frac{Recall_{low} + Recall_{mid} + Recall_{high}}{3}$$

$$Balanced\ Accuracy = \frac{0 + 1 + 0}{3} = 0.33$$

Baselines para classificação: maioria e o perigo da accuracy

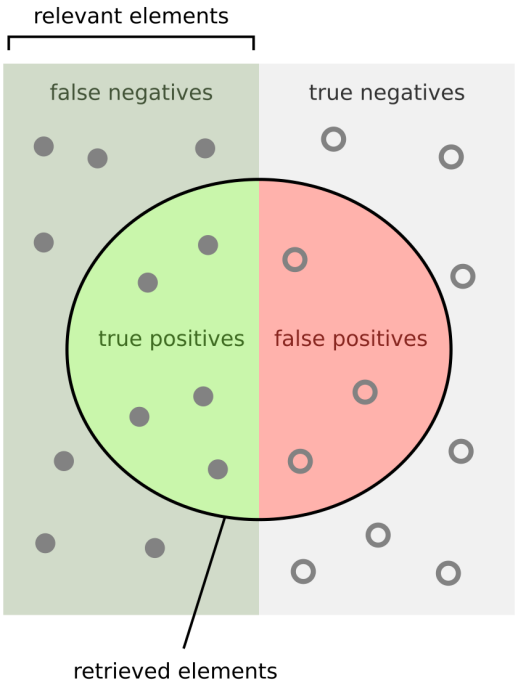

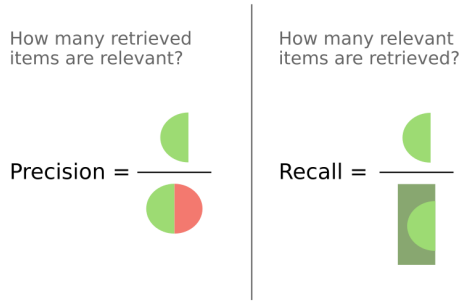

Confusion Matrix

	Actually Positive (1)	Actually Negative (0)
Predicted Positive (1)	True Positives (TPs)	False Positives (FPs)
Predicted Negative (0)	False Negatives (FNs)	True Negatives (TNs)

Protocolo de avaliação: a sequência correta

Step 1 — definir o problema

- regressão: SalePrice
- classificação: classe de preço derivada
- métricas principais e complementares

Step 2 — fazer o split

- train / validation / test
- seed fixa
- estratificação na classificação, se necessário

Step 3 — ajustar baselines no treino

- regressão: média e/ou mediana de SalePrice_train
- classificação: classe mais frequente em price_tier_train

Step 4 — avaliar na validação

- obter previsões dos baselines
- calcular métricas
- treinar primeiro modelo
- calcular métricas no mesmo conjunto

Step 5 — comparar e decidir

- baseline vs modelo
- melhoria real ou só aparente?
- manter o teste intocado

Step 6 — usar o teste só no fim

- avaliar apenas a solução final escolhida
- reportar desempenho final uma única vez

Obrigado!